

SEGMENTACIÓN AUTOMÁTICA DE TUMORES CEREBRALES A PARTIR DE IMÁGENES DE RESONANCIA MAGNÉTICA ESTRUCTURAL

Fundamentos de Deep Learning

Isabella Ariza Cuberos, 1.152.470.641, isabella.ariza@udea.edu.co

Luisa María Zapata Saldarriaga, 1.035.235.580, luisa.zapatas@udea.edu.co

CONTEXTO

Los tumores cerebrales representan un desafío médico, ya que su presencia puede generar complicaciones graves para la salud al ejercer presión sobre áreas cerebrales vitales y desencadenar una amplia gama de problemas, dependiendo de su ubicación [1]. Entre estos desafíos se incluyen la resistencia a la terapia, la alteración del suministro sanguíneo que dificulta la entrega efectiva de medicamentos, complicaciones asociadas al edema cerebral, la hipertensión intracraneal, episodios de convulsiones y efectos neurotóxicos [2].

El diagnóstico de tumores cerebrales es fundamental para iniciar un tratamiento efectivo a tiempo. En este sentido, las técnicas de imagen permiten realizar un apoyo diagnóstico no invasivo, siendo la resonancia magnética (RM) una de las más utilizadas. Sin embargo, para realizar un diagnóstico adecuado y planificar un tratamiento, es necesario realizar un proceso de segmentación de los tumores en las imágenes de RM. La segmentación permite una delimitación de las estructuras afectadas, proporcionando información de tamaño, forma y características específicas del tumor, lo que facilita la evaluación de su comportamiento y la planificación de intervenciones terapéuticas personalizadas. No obstante, estos procesos usualmente se realizan de forma manual, por un radiólogo experto, lo que hace que sea una tarea que toma mucho tiempo y es propensa a la variabilidad entre diferentes observadores [3].

Para abordar esta problemática, se han desarrollado métodos semiautomatizados y automatizados de segmentación de estructuras anatómicas o patológicas, que van desde enfoques basados en regiones hasta algoritmos avanzados de aprendizaje automático y técnicas especializadas de aprendizaje profundo que permitan disminuir los tiempos de segmentación conservando al máximo la precisión de esta [4].

OBJETIVO

Predecir la segmentación de áreas tumorales utilizando imágenes de resonancia magnética estructural multimodales.

DATASET

El conjunto de datos seleccionado corresponde a los datos del desafío BraTS 2021 (Brain Tumor Segmentation).

Este dataset incluye imágenes de resonancia magnética estructural de 1.239 sujetos, cada uno de ellos contiene 4 modalidades de imágenes:

1. T1
2. T2
3. FLAIR
4. T1ce – Post contraste

Además, contiene las etiquetas de segmentación para cada una de las clases que conforman el tumor anotadas de la siguiente forma:

ETIQUETA	CLASE	DESCRIPCIÓN
1	NCR	Núcleo del tumor necrótico
2	ED	Edema peritumoral
3	ET	Tumor realzado con gadolinio (contraste)

MÉTRICAS DE DESEMPEÑO DE MACHINE LEARNING Y NEGOCIO

❖ Machine Learning

Para evaluar el rendimiento del modelo, es crucial utilizar métricas de evaluación adecuadas. Si bien la precisión es una medida comúnmente empleada, puede resultar engañosa en conjuntos de datos desequilibrados, como en el caso de BraTS2021. Por ello, además de la precisión, incorporaremos otras métricas como la Intersección sobre Unión (IoU), el coeficiente de Dice, la sensibilidad, la especificidad y el valor predictivo positivo.

- La precisión (Accuracy) se utiliza para medir la proporción general de píxeles clasificados correctamente, abarcando tanto los positivos como los negativos.
- La Intersección sobre Unión (IoU) evalúa la superposición entre las segmentaciones predichas y las segmentaciones de verdad fundamental.
- La Sensibilidad (Recall o Tasa de Positivos Verdaderos) cuantifica la proporción de píxeles positivos de verdad fundamental que han sido correctamente predichos como positivos.
- El Valor Predictivo Positivo (Precisión) mide la proporción de píxeles positivos predichos que realmente son positivos.
- La Especificidad (Tasa de Negativos Verdaderos) determina la proporción de píxeles negativos de verdad fundamental que han sido correctamente predichos como negativos.

❖ Negocio

Precisión de la segmentación: La precisión con la que el modelo puede detectar y segmentar regiones de interés en las imágenes podría traducirse en una mejor detección temprana de enfermedades o una mejor planificación del tratamiento, lo cual es esencial para mejorar los resultados clínicos.

RESULTADOS PREVIOS

Los enfoques de aprendizaje profundo eliminan la necesidad de una preselección de características, ya que pueden entrenarse utilizando directamente las métricas más relevantes para la clasificación o predicción. En el artículo presentado por Shaver et al, se realiza una revisión de los diferentes métodos de aprendizaje profundo orientados a la detección, caracterización y predicción de resultados relacionados con gliomas [5]. Este trabajo proporciona una visión general de las diversas metodologías que ofrecen soluciones dirigidas hacia la iniciativa de medicina de precisión en el tratamiento y manejo de los gliomas.

Entre los métodos expuestos en este trabajo se incluyen: Hybrid deep and machine learning CNN-LSTM, Multi-Scale CNN, ResNet (50, 36, 18), Residual CNN, CNN, Multimodal 3D DenseNet, Multimodal 3D DenseNet con transferencia de aprendizaje, CRNN y ANN [5]. Además, existen otras alternativas como U-Net, una técnica de segmentación de imágenes que se posiciona actualmente como una arquitectura de red de aprendizaje profundo eficaz para la segmentación precisa y eficiente.

U-Net se divide en dos componentes principales: el codificador (front-end) y el decodificador (back-end). El codificador tiene como objetivo reducir la muestra de la imagen de entrada y extraer características utilizando capas convolucionales y de agrupación. Por otro lado, el decodificador se encarga de muestrear y restaurar la imagen a su tamaño original, permitiendo extraer información detallada y focalizada.

El estudio presentado por Zhao et al, amplía la investigación sobre el rendimiento de la codificación de EfficientNet, lo cual aborda las limitaciones y mejora la susceptibilidad de U-Net al sobreajuste, especialmente en casos de muestras limitadas [6]. Esta mejora resulta en una capacidad de generalización reducida cuando se aplica a nuevos datos de prueba. En 2021, Google desarrolló una segunda versión de este modelo, que combina las fortalezas de MBConv y Fused-MBConv para mejorar el rendimiento mientras gestiona eficientemente los parámetros en términos de computación y precisión. Los resultados de entrenamiento, validación y prueba de este trabajo muestran un mejor rendimiento de segmentación entre EfficientUnet en comparación con el modelo U-Net original. Sin embargo, este enfoque presenta una limitación en cuanto a la agregación de múltiples experimentos. Abordar los desafíos asociados con la precisión de la segmentación de tumores cerebrales es de importancia para avanzar en los problemas de salud, al proporcionar alternativas de apoyo diagnóstico con mayor confiabilidad y robustez.

REFERENCIAS

- [1] Poon MTC, Sudlow CLM, Figueroa JD, et al. Longer-term (≥ 2 years) survival in patients with glioblastoma in population-based studies pre- and post-2005: a systematic review and meta-analysis. *Sci Rep.* 2020;10(1):11622. <https://doi.org/10.1038/s41598-020-68011-4>.
- [2] W.L. Bi, A. Hosny, M.B. Schabath, M.L. Giger, N.J. Birkbak, A. Mehrtash, T. Allison, O. Arnaout, C. Abbosh, I.F. Dunn, et al., Artificial intelligence in cancer imaging: Clinical challenges and applications, *CA: Cancer J. Clin.* 69 (2) (2019) 127–157.
- [3] G. Shukla, G.S. Alexander, S. Bakas, R. Nikam, K. Talekar, J.D. Palmer, W. Shi, Advanced magnetic resonance imaging in glioblastoma: A review, *Chin. Clin. Oncol.* 6 (4) (2017) 40.
- [4] M.K. Abd-Ellah, A.I. Awad, A.A. Khalaf, H.F. Hamed, A review on brain tumor diagnosis from MRI images: practical implications, key achievements, and lessons learned, *Magn. Reson. Imag.* 61 (2019) 300–318.
- [5] Shaver MM, Kohanteb PA, Chiou C, Bardis MD, Chantaduly C, Bota D, Filippi CG, Weinberg B, Grinband J, Chow DS, Chang PD. Optimizing Neuro-Oncology Imaging: A Review of Deep Learning Approaches for Glioma Imaging. *Cancers (Basel).* 2019 Jun 14;11(6):829. doi: 10.3390/cancers11060829. PMID: 31207930; PMCID: PMC6627902.
- [6] Lin SY, Lin CL. Brain tumor segmentation using U-Net in conjunction with EfficientNet. *PeerJ Comput Sci.* 2024 Jan 2;10:e1754. doi: 10.7717/peerj-cs.1754. PMID: 38196955; PMCID: PMC10773611.